29.01.2026

Dokumentacja Techniczna Projektu: Online shop activity analysis

Bugdol Mateusz ● Kowalski Kajetan ● Orlikowski Przemysław

1. Cel projektu

Celem projektu “Online shop activity analysis” jest wdrożenie skalowalnego systemu przetwarzania danych w czasie rzeczywistym (Real-Time Data Streaming), który umożliwia monitorowanie zachowań użytkowników sklepu internetowego.

System realizuje architekturę Medallion (Bronze-Silver-Gold) na platfirmie Azure Databricks, dostarczając kluczowe metryki biznesowe, takie jak konwersja sprzedaży, wykrywanie porzuconych koszyków oraz analiza przychodów w ujęciu sesyjnym.

2. Architektura Rozwiązania

System oparty jest na chmurze Microsoft Azure i wykorzystuje następujące komponenty:

1. **Źródło Danych:** Symulator ruchu (Python) generujący zdarzenia JSON.
2. **Ingestia:** Azure Event Hubs (kolejkowanie strumienia zdarzeń).
3. **Przetwarzanie (Compute):** Apache Spark (Databricks) w trybie Structured Streaming.
4. **Magazyn Danych:** Azure Data Lake Storage Gen2 (format Delta Lake).
5. **Orkiestracja i Infrastruktura:** Terraform (IaC) oraz GitHub Actions (CI/CD).

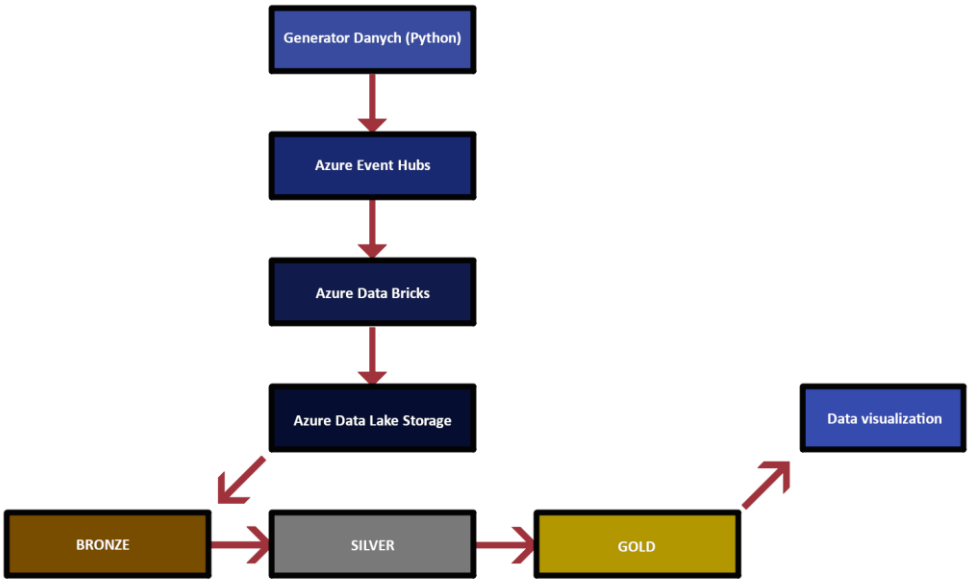

(Rys. 1. Diagram architektury systemu)

3. Infrastruktura (Infrastracture as a Code)

Całe środowisko jest definiowane i wdrażane automatycznie przy użyciu narzędzia **Terraform**.

3.1. Zasoby Azure

- Resource Group: *rg-clickstream-student-dev (*kontener logiczny zasobów).
- **Storage Account:** Data Lake Gen2 (*stclickstream...)* z włączoną hierarchiczną przestrzenią nazw. Kontener data przechowuje tabele Delta.
- **Event Hubs:** Namespace i Hub (*input-stream*) z 2 partycjami do odbioru danych.
- **Databricks Workspace:** Środowisko pracy analitycznej.
- Zmienne konfiguracyjne Terraform:

Nazwa zmiennej	Opis	Wartość domyślna
resource_group_name	Nazwa grupy zasobów	rg-clickstream-student-dev
location	Region Azure	Switzerland North
alert_email	Email do alertów budżetowych	twoj@email.com

3.2. Konfiguracja klastra

Skrypt Terraform automatycznie powołuje klaster *Clickstream Cluster*:

- **Typ:** Single Node (rozmiar *Standard_DS3_v2*).
- **Runtime:** Databricks Runtime 13.3 LTS (Scala 2.12, Spark 3.x).
- **Biblioteki:** Zainstalowany konektor Maven *com.microsoft.azure:azure-eventhubs-spark*.
- **Bezpieczeństwo:** Klucze dostępowe (Connection Strings) są wstrzykiwane jako zmienne środowiskowe (*EVENT_HUB_CONN_STR*, *STORAGE_ACCOUNT_KEY*), co eliminuje konieczność ich twardego kodowania.

3.2. Zarządzanie Kosztami i Monitoring (FinOps)

W celu kontroli wydatków chmurowych, w infrastrukturze zdefiniowano zasób `azurerm_consumption_budget_resource_group`, który monitoruje koszty generowane przez grupę zasobów w cyklu miesięcznym.

- **Budżet miesięczny:** Ustalony na sztywno limit **50 jednostek walutowych** (zależnie od waluty subskrypcji Azure).
- **Alerty kosztowe:** System automatycznie wysyła powiadomienia e-mail w momencie przekroczenia określonych progów zużycia budżetu:
  - **10%:** Wczesne ostrzeżenie o rozpoczęciu naliczania kosztów.
  - **50%:** Powiadomienie o wykorzystaniu połowy budżetu.
  - **75%:** Ostrzeżenie krytyczne przed wyczerpaniem środków.
- **Adresat:** Powiadomienia trafiają na adres zdefiniowany w zmiennej `alert_email` (domyślnie konfigurowalny w pliku `variables.tf`).

4. Generator Danych (Symulacja)

Aplikacja Python (*mock_data.py*) symuluje ruch użytkowników na stronie sklepu.

- **Generowane zdarzenia:** *PAGE_VIEW, SEARCH, PRODUCT_VIEW, ADD_TO_CART, PURCHASE.*
- **Struktura danych:** Zdarzenia zawierają ID użytkownika, ID sesji, czas (Timestamp), dane urządzenia oraz szczegóły produktu (cena, kategoria).
- **Konfiguracja:** Skrypt automatycznie pobiera parametry połączenia z pliku *.env*, generowanego przez Terraform podczas wdrożenia infrastruktury.

5. Przetwarzanie Danych (ETL Pipeline)

Logika ETL zaimplementowana jest w notebooku *medallion_pipeline* z wykorzystaniem **Spark Structured Streaming**.

5.1. Warstwa Bronze (Raw)

- **Zadanie:** Pobranie strumienia z Event Hubs.
- **Format:** Dane zapisywane są w formacie Delta w trybie *append*.
- **Charakterystyka:** Dane są surowe, nieprzetworzone, służą jako historyczne źródło prawdy.

5.2. Warstwa Silver (Cleansed)

- **Parsowanie:** Rozpakowanie pola *body* z formatu binarnego do struktury JSON.
- **Typowanie:** Rzutowanie pól na odpowiednie typy (Timestamp, Double).
- **Watermarking:** Ustawienie 10-minutowego progu tolerancji dla opóźnionych danych.
- **Deduplikacja:** Usuwanie powtórzeń na podstawie unikalnego *eventId*.

5.3. Warstwa Gold (Aggregated Business Logic)

Warstwa ta tworzy gotowe do analizy statystyki sesji (`gold_session_stats`).

- **Session Windows:** Grupowanie zdarzeń w **30-minutowe okna sesji** (brak aktywności przez 30 min zamyka sesję).
- **Logika Biznesowa:**
  - *is_purchased*: Flaga oznaczająca sfinalizowanie transakcji.
  - `is_abandoned_cart`: Wykrywanie sytuacji, gdy użytkownik dodał produkt do koszyka, ale nie kupił.
  - `session_revenue`: Suma wartości zakupów w sesji.
- **Tryb Zapisu:** `OutputMode.Complete` (aktualizacja stanu dla całego okna).

6. Raportowanie i Wizualizacja

Notebook `dashboard_visualization` pełni rolę warstwy prezentacyjnej, generując interaktywne wykresy:

6.1. **Główne KPI:** Liczniki całkowitej sprzedaży, liczby sesji, porzuconych koszyków i przychodu.

6.2. **Lejek Konwersji (Funnel):** Wizualizacja etapów: *Wszystkie Sesje -> Aktywność w Koszyku -> Zakup*.

6.3. **Analiza Czasowa:** Wykres liniowy pokazujący natężenie ruchu i sprzedaży w godzinowych oknach czasowych.

6.4. **Top Klienci:** Tabela rankingowa użytkowników z najwyższym LTV (Lifetime Value).

7. DevOps i CI/CD (Github Actions)

Projekt wykorzystuje dwa automatyczne przepływy pracy (Workflows) do zapewnienia jakości kodu.

7.1. Auto format and Lint

- **Wyzwalacz**: Pull Request do main.
- **Działanie**: Automatycznie formatuje kod Python (Black, Isort) i Terraform (terraform fmt). Usuwa nieużywane importy (Autoflake).
- **Cel**: Utrzymanie spójnego stylu kodu bez integracji programisty.

8. Instrukcja Uruchomienia (Deployment)

1. **Infrastruktura:**

```
cd iac
terraform init
terraform apply
```

Po zakończeniu zostanie utworzony plik `.env` z kluczami dostępu.

2. Generator Danych:

```
cd ../data_generator
python mock_data.py
```

3. Uruchomienie Pipeline'u

- Zaloguj się do Azure Databricks.
- Uruchom klaster `Clickstream Cluster`.
- Otwórz notebook `medallion_pipeline` i kliknij "Run All".
- **Analiza**:
  - Otwórz notebook `dashboard_visualization` i odświeżaj wykresy, aby obserwować napływające dane.

9. Estymowane koszty systemu:

Usługa	Warstwa/Typ	Szacowany miesięczny koszt [USD]
Azure Event Hubs	Standard	~$5
Azure Databricks	Standard_DS3_v2	~$120
Storage Account	Standard LRS	~$1-2
	SUMA:	~$127

10. Screeny

```
status_df = df.withColumn(
    "session_status",
    when(col("is_purchased") == 1, "Purchased")
    .when(col("is_abandoned_cart") == 1, "Abandoned Cart")
    .otherwise("Browsing Only"),
)

display(status_df.groupBy("session_status").count())
```

(2) Spark Jobs

status_df: pyspark.sql.dataframe.DataFrame = [userId: string, window_start: timestamp ... 6 more fields]

Table

	session_status	count
1	Purchased	714
2	Abandoned Cart	1096
3	Browsing Only	2536

3 rows | 3.32s runtime

Refreshed 2 minutes ago

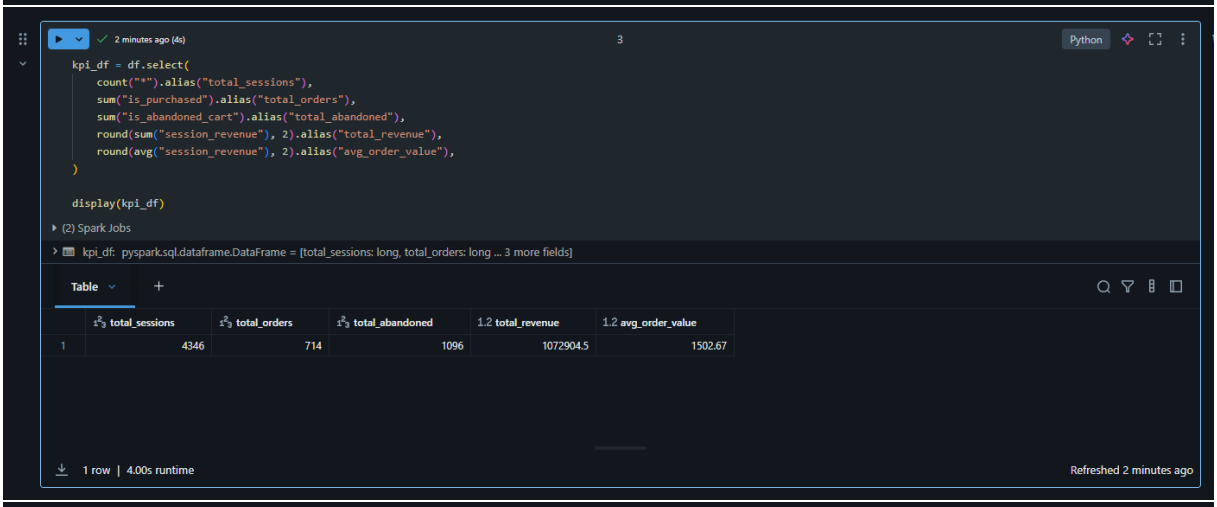

```
kpi_df = df.select(
    count("*").alias("total_sessions"),
    sum("is_purchased").alias("total_orders"),
    sum("is_abandoned_cart").alias("total_abandoned"),
    round(sum("session_revenue"), 2).alias("total_revenue"),
    round(avg("session_revenue"), 2).alias("avg_order_value"),
)

display(kpi_df)
```

(2) Spark Jobs

kpi_df: pyspark.sql.dataframe.DataFrame = [total_sessions: long, total_orders: long ... 3 more fields]

Table

	total_sessions	total_orders	total_abandoned	total_revenue	avg_order_value
1	4346	714	1096	1072904.5	1502.67

1 row | 4.00s runtime

Refreshed 2 minutes ago

```
display(df)
```

(3) Spark Jobs

Table

	userId	window_start	window_end	events_count	is_purchased	session_revenue	is_abandoned_cart
1	user_2053	2026-01-29T18:55:12.184+00:...	2026-01-29T19:25:35.258+00:...	3	0	null	0
2	user_7536	2026-01-29T19:56:22.796+00:...	2026-01-29T20:26:37.577+00:...	2	0	null	0
3	user_9688	2026-01-29T19:35:00.447+00:...	2026-01-29T20:09:11.839+00:...	3	0	null	0
4	user_8713	2026-01-29T18:25:22.264+00:...	2026-01-29T18:55:39.694+00:...	3	0	null	0
5	user_2053	2026-01-29T18:23:50.028+00:...	2026-01-29T18:54:05.333+00:...	3	0	null	0
6	user_2968	2026-01-29T18:47:53.003+00:...	2026-01-29T19:18:08.771+00:...	4	0	null	0
7	user_1988	2026-01-29T19:36:29.140+00:...	2026-01-29T20:06:44.856+00:...	2	0	null	0
8	user_3001	2026-01-29T19:45:48.011+00:...	2026-01-29T20:16:09.842+00:...	7	0	null	1
9	user_5069	2026-01-29T18:16:25.410+00:...	2026-01-29T18:46:40.706+00:...	5	0	null	1
10	user_6754	2026-01-29T18:23:05.310+00:...	2026-01-29T18:53:38.315+00:...	4	1	350	0
11	user_3685	2026-01-29T19:01:28.349+00:...	2026-01-29T19:42:49.324+00:...	4	0	null	1
12	user_7342	2026-01-29T19:06:17.060+00:...	2026-01-29T19:36:17.060+00:...	1	0	null	0
13	user_9634	2026-01-29T19:05:27.819+00:...	2026-01-29T19:35:37.323+00:...	4	0	null	0
14	user_4358	2026-01-29T19:01:35.993+00:...	2026-01-29T19:38:59.912+00:...	10	1	5300	0
15	user_8960	2026-01-29T19:36:00.239+00:...	2026-01-29T20:06:18.123+00:...	3	0	null	1

4,346 rows | 3.69s runtime

Refreshed 2 minutes ago

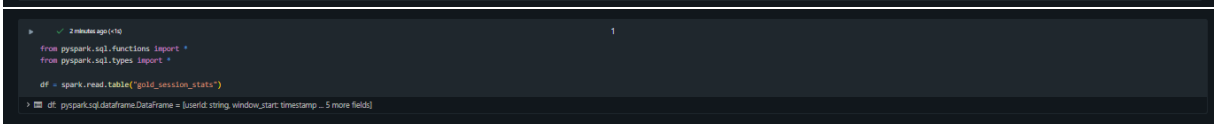

```
from pyspark.sql.functions import *
from pyspark.sql.types import *

df = spark.read.table("gold_session_stats")
```

df: pyspark.sql.dataframe.DataFrame = [userId: string, window_start: timestamp ... 5 more fields]

Interrupt 4 Python

```python
silver_stream = spark.readStream.table("silver_clickstream")

gold_df = (
    silver_stream.groupBy(
        col("userId"),
        session_window(col("event_time"), "30 minutes").alias("session_window"),
    )
    .agg(
        count("*").alias("events_count"),
        max(when(col("eventType") == "PURCHASE", 1).otherwise(0)).alias("is_purchased"),
        max(when(col("eventType") == "ADD_TO_CART", 1).otherwise(0)).alias(
            "has_cart_activity"
        ),
        sum(col("total_amount")).alias("session_revenue"),
        min("event_time").alias("session_start"),
        max("event_time").alias("session_end"),
    )
    .select(
        col("userId"),
        col("session_window.start").alias("window_start"),
        col("session_window.end").alias("window_end"),
        col("events_count"),
        col("is_purchased"),
        col("session_revenue"),
        when((col("has_cart_activity") == 1) & (col("is_purchased") == 0), 1)
        .otherwise(0)
        .alias("is_abandoned_cart"),
    )
)

gold_query = (
    gold_df.writeStream.format("delta")
    .outputMode("complete")
    .option("checkpointLocation", f"{base_path}/checkpoints/gold")
    .table("gold_session_stats")
)
```

(1) Spark Jobs

1ffd3c85-cc75-4a72-896e-671ffb2c7c07 *Last updated: 1 minute ago*

gold_df: pyspark.sql.dataframe.DataFrame = [userId: string, window_start: timestamp ... 5 more fields]
silver_stream: pyspark.sql.dataframe.DataFrame = [eventId: string, eventType: string ... 8 more fields]

Interrupt 3 Python

```python
json_schema = StructType(
    [
        StructField("eventId", StringType(), True),
        StructField("eventType", StringType(), True),
        StructField("timestamp", TimestampType(), True),
        StructField("userId", StringType(), True),
        StructField("sessionId", StringType(), True),
        StructField("pageUrl", StringType(), True),
        StructField(
            "device",
            StructType(
                [
                    StructField("type", StringType(), True),
                    StructField("os", StringType(), True),
                    StructField("ip", StringType(), True),
                ]
            ),
            True,
        ),
        StructField(
            "data",
            StructType(
                [
                    StructField("productId", StringType(), True),
                    StructField("productName", StringType(), True),
                    StructField("price", DoubleType(), True),
                    StructField("currency", StringType(), True),
                    StructField("searchQuery", StringType(), True),
                    StructField("totalAmount", DoubleType(), True),
                ]
            ),
            True,
        ),
    ]
)

bronze_df = spark.readStream.table("bronze_clickstream")

silver_df = (
    bronze_df.select(from_json(col("body").cast("string"), json_schema).alias("parsed"))
    .select("parsed.*")
    .withColumn("event_time", col("timestamp").cast("timestamp"))
    .withColumn("total_amount", col("data.totalAmount"))
    .withWatermark("event_time", "10 minutes")
    .dropDuplicates(["eventId", "event_time"])
)

silver_query = (
    silver_df.writeStream.format("delta")
    .outputMode("append")
    .option("checkpointLocation", f"{base_path}/checkpoints/silver")
    .table("silver_clickstream")
)
```

(1) Spark Jobs

48bc9ef8-6aae-4319-af55-f1bb5b19c88f *Last updated: 25 seconds ago*

bronze_df: pyspark.sql.dataframe.DataFrame = [body: binary, partition: string ... 7 more fields]
silver_df: pyspark.sql.dataframe.DataFrame = [eventId: string, eventType: string ... 8 more fields]

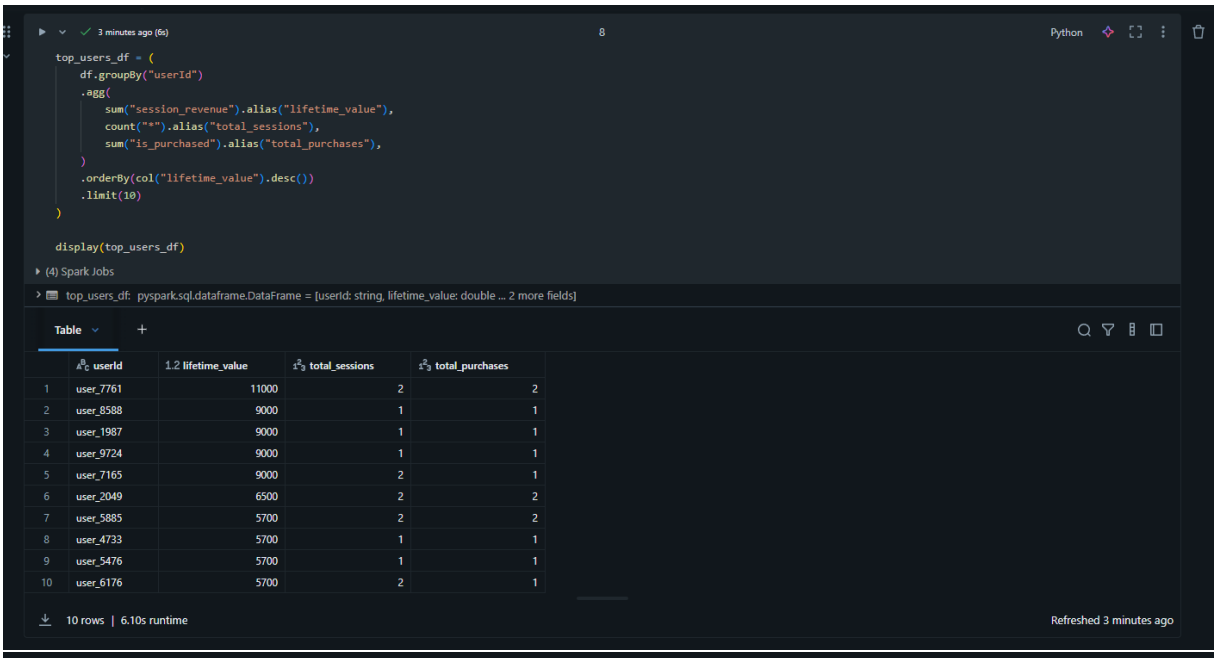

3 minutes ago (6s) 8 Python

```
top_users_df = (
    df.groupBy("userId")
    .agg(
        sum("session_revenue").alias("lifetime_value"),
        count("*").alias("total_sessions"),
        sum("is_purchased").alias("total_purchases"),
    )
    .orderBy(col("lifetime_value").desc())
    .limit(10)
)

display(top_users_df)
```

(4) Spark Jobs

top_users_df: pyspark.sql.dataframe.DataFrame = [userId: string, lifetime_value: double ... 2 more fields]

Table +

	userId	lifetime_value	total_sessions	total_purchases
1	user_7761	11000	2	2
2	user_8588	9000	1	1
3	user_1987	9000	1	1
4	user_9724	9000	1	1
5	user_7165	9000	2	1
6	user_2049	6500	2	2
7	user_5885	5700	2	2
8	user_4733	5700	1	1
9	user_5476	5700	1	1
10	user_6176	5700	2	1

10 rows | 6.10s runtime Refreshed 3 minutes ago

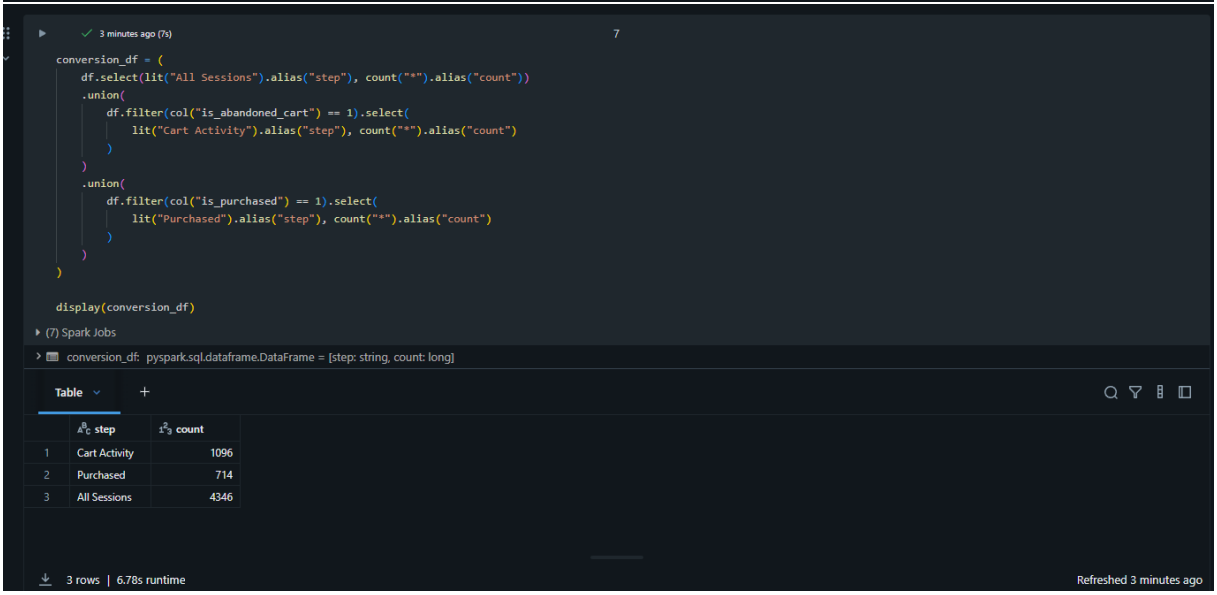

3 minutes ago (7s) 7

```
conversion_df = (
    df.select(lit("All Sessions").alias("step"), count("*").alias("count"))
    .union(
        df.filter(col("is_abandoned_cart") == 1).select(
            lit("Cart Activity").alias("step"), count("*").alias("count")
        )
    )
    .union(
        df.filter(col("is_purchased") == 1).select(
            lit("Purchased").alias("step"), count("*").alias("count")
        )
    )
)

display(conversion_df)
```

(7) Spark Jobs

conversion_df: pyspark.sql.dataframe.DataFrame = [step: string, count: long]

Table +

	step	count
1	Cart Activity	1096
2	Purchased	714
3	All Sessions	4346

3 rows | 6.78s runtime Refreshed 3 minutes ago

3 minutes ago (3s) 6

```
revenue_df = (
    df.filter(col("session_revenue") > 0)
    .select("userId", "session_revenue", "window_start")
    .orderBy(col("window_start").desc())
)

display(revenue_df)
```

(1) Spark Jobs

revenue_df: pyspark.sql.dataframe.DataFrame = [userId: string, session_revenue: double ... 1 more field]

Table +

	userId	session_revenue	window_start
1	user_2049	1200	2026-01-29T20:00:13.746+00:...
2	user_5799	350	2026-01-29T20:00:07.469+00:...
3	user_3126	120.5	2026-01-29T19:59:45.152+00:...
4	user_1837	350	2026-01-29T19:59:38.628+00:...
5	user_7629	800	2026-01-29T19:59:29.627+00:...
6	user_6881	120.5	2026-01-29T19:59:29.627+00:...
7	user_4054	120.5	2026-01-29T19:59:24.491+00:...
8	user_7360	1200	2026-01-29T19:59:20.035+00:...
9	user_5885	4500	2026-01-29T19:59:12.769+00:...
10	user_9110	120.5	2026-01-29T19:58:54.813+00:...
11	user_5419	120.5	2026-01-29T19:58:53.016+00:...
12	user_2461	350	2026-01-29T19:58:53.016+00:...
13	user_5857	120.5	2026-01-29T19:58:48.048+00:...
14	user_7902	120.5	2026-01-29T19:58:26.827+00:...
15	user_7349	1200	2026-01-29T19:58:06.586+00:...

714 rows | 3.26s runtime Refreshed 2 minutes ago

3 minutes ago (3s) 5 Python

```
timeline_df = (
    df.groupBy(window(col("window_start"), "1 hour").alias("time_window"))
    .agg(
        count("*").alias("sessions"),
        sum("is_abandoned_cart").alias("abandoned_count"),
        sum("is_purchased").alias("purchases_count"),
    )
    .orderBy("time_window")
)

display(timeline_df)
```

(2) Spark Jobs

timeline_df: pyspark.sql.dataframe.DataFrame = [time_window: struct, sessions: long ... 2 more fields]

Table +

	time_window	sessions	abandoned_count	purchases_count
1	{"start":"2026-01-29T17:00:00Z","end":"2026-01-29T18:00:...	110	27	14
2	{"start":"2026-01-29T18:00:00Z","end":"2026-01-29T19:00:...	2168	545	363
3	{"start":"2026-01-29T19:00:00Z","end":"2026-01-29T20:00:...	2053	520	335
4	{"start":"2026-01-29T20:00:00Z","end":"2026-01-29T21:00:...	15	4	2

4 rows | 3.30s runtime Refreshed 2 minutes ago

Interrupt 2 Python

```
connectionString = f"{eh_conn_str};EntityPath={eh_name}"
ehConf = {
    "eventhubs.connectionString": sc._jvm.org.apache.spark.eventhubs.EventHubsUtils.encrypt(
        connectionString
    )
}

raw_stream_df = spark.readStream.format("eventhubs").options(**ehConf).load()

bronze_query = (
    raw_stream_df.writeStream.format("delta")
    .outputMode("append")
    .option("checkpointLocation", f"{base_path}/checkpoints/bronze")
    .table("bronze_clickstream")
)
```

(1) Spark Jobs

78440e2e-2359-4a8f-a3f2-3a6c61c9935d *Last updated: 35 seconds ago*

raw_stream_df: pyspark.sql.dataframe.DataFrame = [body: binary, partition: string ... 7 more fields]

```
06:56 PM (2s)                                                    1

import os

from pyspark.sql.functions import *
from pyspark.sql.types import *

eh_conn_str = os.environ.get("EVENT_HUB_CONN_STR")
eh_name = os.environ.get("EVENT_HUB_NAME")
storage_name = os.environ.get("STORAGE_ACCOUNT_NAME")
storage_key = os.environ.get("STORAGE_ACCOUNT_KEY")

spark.conf.set(f"fs.azure.account.key.{storage_name}.dfs.core.windows.net", storage_key)
base_path = f"abfss://data@{storage_name}.dfs.core.windows.net"
```